

Comparación de modelos de tópicos (LDA)

Corpus de reseñas de cine — Soluciones con K = 12, 20 y 25 tópicos

1. Objetivo y datos

Se estimaron tres modelos de tópicos sobre un corpus de reseñas de cine en inglés (del tipo del clásico corpus de polaridad de reseñas), variando el número de tópicos (K = 12, 20 y 25). Para cada solución se examinaron los 15 términos con mayor probabilidad por tópico, se asignaron etiquetas interpretativas y se evaluó la coherencia semántica de cada partición.

2. Etiquetas propuestas por modelo

Modelo con 12 tópicos. Diez tópicos sustantivos: acción/crimen; sexualidad y contenido adulto; romance y drama familiar; ciencia ficción espacial y blockbusters; cómic oscuro/terror-acción; terror adolescente (slasher); Star Wars y cine de efectos especiales; Disney/animación y musicales; cine bélico y político; y comedia. Dos tópicos residuales de vocabulario genérico de reseña.

Modelo con 20 tópicos. Dieciocho tópicos sustantivos, con géneros claramente delimitados: acción de artes marciales/Hong Kong; sexualidad; dramas de personaje (Robin Williams); blockbusters de desastre/monstruos; romance familiar; ciencia ficción espacial; crimen/pulp; Disney/animación; coming-of-age escolar; terror/slasher; Star Wars y épicas de efectos; comedia de actores; adaptaciones de cómic; drama político y judicial; ciencia ficción distópica (Matrix); cine bélico; evaluación humorística; y música/musicales. Dos tópicos residuales.

Modelo con 25 tópicos. Veintidós tópicos sustantivos. Emergen categorías nuevas y coherentes: adaptaciones de series de televisión (Star Trek, X-Files); drama judicial; comedia romántica como categoría propia; cine deportivo; y ciencia ficción distópica bien separada de la espacial. Sin embargo, aparecen también tópicos centrados en películas individuales más que en géneros (Godzilla; Titanic; Good Will Hunting/The Big Lebowski; dramas de estrellas de fines de los 90), así como un tercer tópico residual con sesgo hacia el vocabulario de reseña negativa.

3. Comparación estructural

	K = 12	K = 20	K = 25
Tópicos residuales (vocabulario genérico)	2	2	3
Tópicos sustantivos	10	18	22
Tópicos incoherentes o quiméricos	1	0–1	3–4
Tópicos de película específica (no género)	0	~1	~4

Al aumentar K de 12 a 20, el modelo separa distinciones genuinas que la solución más gruesa fusionaba de manera forzada (por ejemplo, el tópico quimérico que unía Batman, vampiros y Larry Flynt en K = 12 se descompone en tres tópicos limpios en K = 20). Al pasar de 20 a 25, en cambio, las ganancias (televisión, tribunal, comedia romántica, deportes) conviven con una

sobre-segmentación: varios tópicos pasan a capturar películas individuales de alta frecuencia en el corpus en lugar de estructura temática, y el vocabulario residual se fragmenta en tres tópicos de fondo.

4. Hallazgo transversal: el problema del vocabulario

En las tres soluciones persisten tópicos residuales compuestos por vocabulario genérico de reseña (film, movie, one, like, good, bad, story, character). Su estabilidad ante cambios de K indica que no son ruido del modelo sino un problema de preprocesamiento: estos términos de alta frecuencia documental absorben masa de probabilidad en todas las particiones. La recomendación principal es ampliar la lista de stopwords con este vocabulario evaluativo (o filtrar términos por frecuencia documental máxima) y reestimar los modelos, en lugar de seguir ajustando K.

5. Recomendaciones

(a) Preferir provisoriamente la solución $K = 20$: ofrece el mejor equilibrio entre granularidad e interpretabilidad, con géneros nombrables y sin quimeras graves. **(b)** Depurar el vocabulario (stopwords ampliadas o filtro por frecuencia documental) y reestimar los tres modelos. **(c)** Formalizar la selección de K mediante métricas de coherencia por tópico (C_v o NPMI) y exclusividad semántica, graficando el compromiso entre ambas a través de valores de K; esto proporciona un criterio defendible para publicación, superior a la inspección visual de términos. **(d)** Si la sobre-segmentación en películas individuales es indeseable, considerar además la eliminación de nombres propios de alta frecuencia (títulos, actores) o el uso de un modelo estructural (STM) con covariables si el diseño lo permite.

Nota: las etiquetas de tópicos son interpretaciones asignadas manualmente a partir de los 15 términos principales de cada tópico; la validación formal requiere las métricas indicadas en la sección 5.